

Reconocimiento automático de notas del piano


David Rodríguez Bacelar

Kevin Millán Canchapoma

Luca D'angelo Sabín

Jorge Hermo González

7 de mayo de 2022



UNIVERSIDADE DA CORUÑA

Índice

1. Glosario	3
2. Introducción	3
3. Descripción del problema	5
3.1. Restricciones	6
3.2. Características	6
4. Análisis bibliográfico	7
5. Desarrollo	9
5.1. Primera aproximación	9
5.1.1. Descripción	9
5.1.2. Resultados	12
5.1.3. Discusión	14
5.2. Segunda aproximación	17
5.2.1. Descripción	17
5.2.2. Resultados	21
5.2.3. Discusión	23
5.3. Tercera aproximación	24
5.3.1. Descripción	24
5.3.2. Resultados	30
5.3.3. Discusión	32
5.4. Cuarta aproximación	34
5.4.1. Descripción	34
5.4.2. Resultados	40
5.4.3. Discusión	42
5.5. Quinta aproximación	43
5.5.1. Descripción	43
5.5.2. Resultados	46
5.5.3. Discusión	48
6. Conclusiones	49
7. Trabajo futuro	49
8. Bibliografía	49

1. Glosario

- Sample: muestra de carácter musical
- Cover: Reinterpretación de una canción por parte de alguien diferente al que la compuso.
- VP: Verdadero positivo
- VN: Verdadero negativo
- FP: Falso positivo
- FN: Falso negativo
- RNA: Red de neuronas artificiales.
- SVM: *Support Vector Machine* (Máquina de soporte vectorial).
- kNN: *K-nearest neighbors* (k vecinos más cercanos).
- poly: *Kernel* polinomial.
- rbf: *Kernel* de función de base radial (Gaussiano)
- sigmoid: *Kernel* sigmoidal

2. Introducción

A raíz de la pandemia, el aumento del interés por el aprendizaje en diferentes ámbitos llegó también a la música, y con él, la aparición de herramientas para aprender a tocar diferentes instrumentos de forma autodidacta.

Así, para cualquiera que esté aprendiendo, el escuchar una canción que te gusta e intentar tocarla es algo que acaba siendo un proceso frustrante y que requiere una gran cantidad de horas intentando sacar las notas que la componen.

Nuestro sistema se encargaría entonces de reconocer y diferenciar a partir de audios las notas de una pieza de piano pudiendo, en un futuro, ser capaz de detectar acordes y tonalidades, siendo útil en aplicaciones como Spotify, Tidal... Para ello, haremos uso de diferentes técnicas de aprendizaje automático como las redes de neuronas artificiales, árboles de decisión y máquinas de soporte vectorial, comparando su rendimiento y eligiendo la que mejor resultados nos ofrezca.

A lo largo de esta memoria analizaremos a fondo el problema a resolver en la Sección 3, desarrollaremos las diferentes soluciones en la Sección 5, hablaremos sobre las conclusiones del trabajo en la Sección 6 y finalizaremos comentando las aplicaciones al

mundo real en la Sección 7. También se podrá consultar las bibliografía utilizada en la Sección 4 y 8.

Para el análisis utilizaremos distintas técnicas de aprendizaje supervisado como son:

- Las **Redes de Neuronas Artificiales** o *RNAs*, un modelo de aprendizaje automático clásico que intenta simular el funcionamiento natural del cerebro, haciendo uso de estructuras como las neuronas artificiales y en la que la información se almacena y modifica en los pesos de las conexiones de dichas neuronas. Ver Krogh, 2008.
- **Support Vector Machine** o *SVMs*, un modelo basado, como en las *RNAs*, en la división del espacio del problema para clasificar los diferentes patrones y del que se puede profundizar más en el artículo que las introduce de Cortes y Vapnik, 1995.
- **Árboles de decisión**, técnicas que permiten también subdividir el espacio donde se sitúan los patrones, esta vez siguiendo una estructura de árbol donde se va tomando una rama u otra en función del valor de los distintos atributos. Ver Myles y col., 2004.
- **k-Nearest Neighbors** o *k-NN*, un método con un enfoque diferente, basado en instancias, donde la clasificación se realiza en función de los patrones que más se parecen al de entrada. Ver Guo y col., 2003.

3. Descripción del problema

Nuestro sistema se centrará en reconocer, a partir de un audio, la nota del piano que se está tocando. Escogimos este instrumento por la cantidad de recursos que podemos encontrar y por su naturaleza invariable al ser tocada por una u otra persona.

Dada la naturaleza de nuestro sistema, descartamos utilizar la especificidad o la sensibilidad ya que nos es indiferente las clases en las que se clasifiquen las notas (el coste de un falso positivo o un falso negativo es el mismo).

Así, como solo nos interesa una correcta clasificación global, pensamos en utilizar la precisión, la cual sigue la fórmula:

$$Precision = \frac{VN + VP}{(VN + FN + VP + FP)} \quad (1)$$

El inconveniente de esta métrica está en que si tenemos un conjunto de patrones desbalanceado (gran diferencia en el número de patrones positivos y negativos), la precisión podría alcanzar valores muy altos con sistemas que clasifiquen todos los patrones en la clase con mayor número de ellos en el entrenamiento.

La métrica que utilizaremos entonces para valorar los resultados obtenidos y que palia los problemas mencionados anteriormente será la **F1-score**. Esta se corresponde con la media armónica de la sensibilidad y el valor predictivo positivo y está caracterizada por la fórmula:

$$F1 - Score = \left(\frac{Sensibilidad^{-1} + VPP^{-1}}{2} \right)^{-1} \quad (2)$$

donde,

$$Sensibilidad = \frac{VP}{(FN + VP)} \quad (3)$$

$$VPP = \frac{VP}{(VP + FP)}, \quad (4)$$

Quizá el único inconveniente de esta métrica es su difícil interpretación, más allá de comparar los valores que ofrecen diferentes sistemas. El valor más alto que puede alcanzar es de 1 (todos los patrones se clasificaron correctamente) y el más bajo es de 0 (todos los patrones se clasificaron incorrectamente). Entonces, para facilitar la interpretación de la métrica, también se mostrará la precisión de cada modelo, pero se utilizará el F1-Score para determinar el mejor.

3.1. Restricciones

Como única restricción, en dicho audio solo puede haber una nota sonando a la vez para que el sistema sea capaz de reconocerla correctamente.

3.2. Características

La base de datos con la que contamos tiene un total de 5.406 audios con una media de más de 50 *samples* por cada una de las 85 notas del piano (a partir de *C1*), tocadas desde posiciones e intensidades distintas y grabadas con micrófonos diferentes. Dichos *samples* están en formato *.wav* en estéreo, con un *bitrate* de 2304kbps, 24 *bits per sample* y un *sample rate* de 48kHz. Todo ello ocupa un total de 34.5GB en disco. La duración de los *samples* es de $23,735 \pm 14,754$ segundos, siendo la duración mínima de 1,669 segundos y la duración máxima de 73,646 segundos.

Se puede ver un ejemplo del espectrograma de una de las *samples* que vamos a utilizar en la Figura 1.




Figura 1: Notas A5 en tiempo y frecuencia

El origen de la base de datos es una librería de piano de la compañía *FluffyAudio*

(<https://www.fluffyaudio.com/shop/scoringpiano>) grabada en 2016 y pensada para jazz, música clásica y bandas sonoras.

4. Análisis bibliográfico

Para profundizar en el tema antes de abordarlo, en esta sección se analizan diferentes artículos científicos relacionados con la inteligencia artificial y el reconocimiento de audio, ya sea específicamente relacionado o no con el mundo del reconocimiento de piezas o notas musicales.

Trabajos como el de Osmalsky y col., 2012 nos aportan nuevos enfoques, en el que, en lugar de detectar las notas por separado, analizan todo el espectro de frecuencias para poder reconocer acordes completos de diferentes instrumentos; utilizan una técnica llamada Pitch Class Profile (PCP), que obtiene las relaciones energéticas de cada nota en la escala a partir de un audio.

Además, como resumen Benetos y col., 2018, a pesar del estado avanzado de la transcripción automática de canciones, aún están presentes retos tales como la independencia de los instrumentos, de los estilos musicales o la interpretación de la expresividad.

Otros trabajos mas antiguos como los de Foo y Wong, 1999, describen un algoritmo capaz de reconocer notas de un piano a partir de piezas sintetizadas o acústicas, que son digitalmente muestreadas y transformadas al dominio de frecuencia usando la transformada de Q constante a partir de la cual se la aplican diferentes técnicas para identificar las notas.

En un terreno más general, trabajos como el de Chang y col., 2017, exploran la identificación de *covers* utilizando estructuras más novedosas que no desarrollaremos en este trabajo como son las Redes de Neuronas Convolucionales. Las salidas de este sistema corresponderían con la probabilidad de ser una *cover* (comparándola con la canción original), y se ordenarían por dicha probabilidad elaborando un ranking.

También encontramos la tesis de Klapuri, 2004 que propone un sistema capaz de generar una representación simbólica a partir de un audio, centrándose en el desarrollo de los algoritmos que pueden ser usados para detectar y observar sonidos harmónicos en señales polifónicas. Los cuales fueron evaluados aplicandolos en un programa de transcripción de música para piano implementado y simulado en un entorno Matlab.

En el trabajo de Marolt y col., 2002 destacamos el uso de sistemas conexionistas para la detección de inicio en señales musicales basandose en la combinacion de un banco de filtros auditivos , un red neuronal pulsante y un perceptron multicapa. Este uso de sistemas conexionistas también es empleado para sistemas de transcripción de musica de piano polifónico, mostrando ciertas ventajas sobre otros métodos debido a su estructura y presentándose como una alternativa viable a los algoritmos ya existentes

El uso de redes de neuronas artificiales también están presentes en trabajos como Solanki y Pandey, 2019, que aborda la identificación de los instrumentos que forman parte de piezas polifónicas. Utiliza una red de neuronas convolucional de 8 capas y se apoya en los espectrogramas MEL para mapear datos del audio.

Para finalizar, ya en un campo algo más alejado del musical, podemos destacar el trabajo elaborado por Baevski y col., 2021, el cual profundiza en el campo de reconocimiento del habla mediante inteligencia artificial. A diferencia de otros sistemas de reconocimiento, este trabajo no usa datos etiquetados que limiten el reconocimiento a un grupo reducido de idiomas. Esta técnica necesita menos requerimientos, aprovechando representaciones auto supervisadas del habla para segmentar el audio y aprender a mapear desde estas representaciones a fonemas via *Adversarial Training*.

5. Desarrollo

Para el desarrollo de este sistema utilizaremos un método basado en aproximaciones, es decir, comenzaremos acotando el problema e iremos aumentando la complejidad a medida que obtenemos resultados satisfactorios.

Además, para mejorar la calidad de los experimentos y no depender de la selección aleatoria del conjunto de test y de entrenamiento, utilizaremos la técnica de *cross validation* (validación cruzada). Esta técnica consiste en repetir y calcular la media aritmética obtenida de las medidas de la evaluación sobre k *folds* (conjuntos) distintos.

En concreto, se realizará un *cross validation* con 10 *folds*. El valor del F1-Score y de la precisión del modelo será el promedio de dichos valores obtenidos en los *folds*.

5.1. Primera aproximación

5.1.1. Descripción

En esta primera aproximación nos limitaremos a diferenciar únicamente entre dos notas. Escogimos las notas C_4 y A_5 de los cuales usaremos 92 y 56 audios de cada una, respectivamente, en total se utilizarán 148 patrones. En las Figuras 2a y 2b podemos ver a la izquierda la señal en tiempo y, a la derecha, la señal en el dominio de la frecuencia.

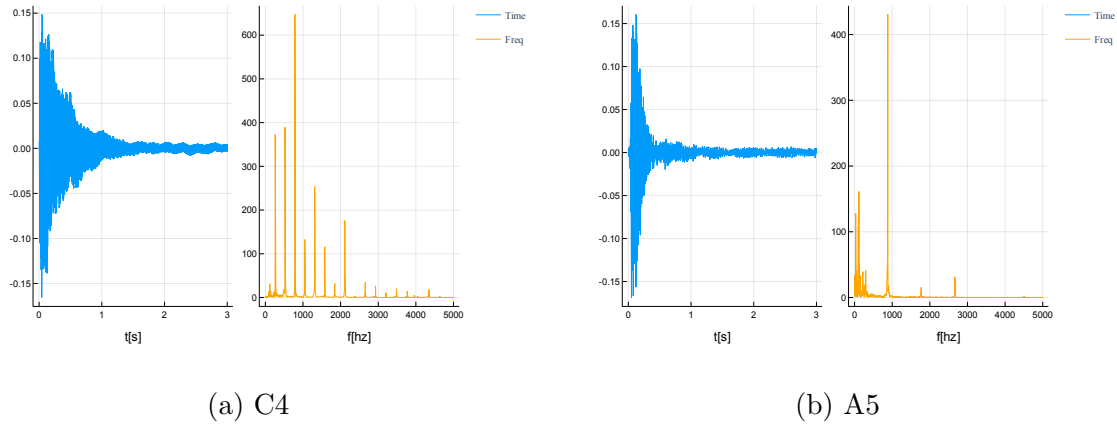


Figura 2: Notas en tiempo y frecuencia

Dado que cada muestra tiene una duración diferente, decidimos quedarnos solo con los 3 primeros segundos de cada audio (que es donde está la información más relevante de la nota) y, para la frecuencia, acotaremos cada señal entre 0 y 5000 Hz. Ya que la frecuencia máxima que se alcanza en el piano clásico es de 4186 Hz (C_8) y la más baja, en nuestra base de datos, es de 32.7Hz (C_1), escogimos un rango de frecuencias ampliado debido a que es posible que exista información que nos ayude a identificar la nota.

Además, como las notas de un mismo instrumento se diferencian principalmente por la frecuencia (una nota más aguda tiene una mayor frecuencia y una más grave, una menor), calcularemos de las señales en el dominio del tiempo su relación en el dominio de la frecuencia utilizando la Transformada de Fourier y, posteriormente, extraeremos las siguientes características:

- **Energía media de la señal:** ya que las señales con más frecuencia (más agudas) tienen más energía, esta característica nos podría ayudar a diferenciar entre notas tocadas con la misma intensidad.
- **Media, desviación típica, y valor máximo de la intensidad en el dominio de la frecuencia, en intervalos no uniformes:** la frecuencia de cada nota aumenta de forma exponencial siguiendo la fórmula:

$$f_{i+1} = f_i \cdot (\sqrt[12]{2}), f_0 = 27,5Hz \quad (5)$$

Por ello decidimos dividir el espectro en **10 intervalos** de longitud variable siguiendo dicha distribución. Podríamos entonces obtener un intervalo donde la media y la desviación típica de la frecuencia fueran más elevados que el resto, ayudándonos a identificar la nota.

Los intervalos que usaremos son los siguientes:

$(0.0, 380.3)$, $(380.3, 783.21)$, $(783.21, 1210.08)$, $(1210.08, 1662.33)$,
 $(1662.33, 2141.47)$, $(2141.47, 2649.11)$, $(2649.11, 3186.93)$, $(3186.93, 3756.73)$,
 $(3756.73, 4360.42)$ y $(4360.42, 5000.0)$

- **Zero-crossing/s:** esta característica determina las veces que la señal, en el dominio del tiempo, toma el valor 0 por segundo. Como dicha característica nos proporcionaría valores similares a la frecuencia media de la señal, podría contribuir a su correcta clasificación.

En lo referente al preprocesado de los datos, hemos decidido optar por una **normalización de media cero**, debido a que los datos no están acotados en un intervalo y pueden tomar cualquier valor, ya sea en tiempo o en frecuencia. Aunque las frecuencias de las notas sí que están acotadas en un intervalo, en la señal puede haber ruido que sobrepase los valores típicos, por lo que una normalización entre mínimo y máximo no sería lo adecuado.

Así, obtuvimos para cada característica, la media y la desviación típica. Se muestran dichos datos en la Tabla 1.

Tabla 1: Parámetros de normalización para cada característica

Característica	Media	Desviación Típica
E	0,0045678928	0,0035726614
zero-crossing	1797,2139	1352,7441
m ₁	16,821161	11,616611
m ₂	9,4079	5,8349323
m ₃	14,607474	11,515968
m ₄	3,8720663	3,5469663
m ₅	2,3520973	2,1539617
m ₆	0,48698702	0,6487291
m ₇	0,7153551	1,0973071
m ₈	0,40077275	0,500489
m ₉	0,22367951	0,3412378
m ₁₀	0,23234393	0,5112222
std ₁	54,282375	46,679535
std ₂	31,582827	27,185955
std ₃	57,896194	38,439426
std ₄	11,108885	12,696077
std ₅	7,0041313	6,732649
std ₆	0,52131796	0,72755563
std ₇	2,7318008	4,6750984
std ₈	0,9234557	1,2807367
std ₉	0,47755784	0,89846444
std ₁₀	0,5695597	1,2890217
max ₁	832,8222	779,30615
max ₂	567,7255	505,1785
max ₃	901,9232	548,2265
max ₄	192,80989	237,47154
max ₅	98,938354	103,55783
max ₆	4,392064	6,0777674
max ₇	40,596066	65,99385
max ₈	11,672165	15,524432
max ₉	5,7904434	10,440257
max ₁₀	5,6131926	11,565159

Donde:

- E indica la **energía de la señal**.
- m_i indica la **media de la intensidad** en el intervalo i en frecuencia.
- std_i indica la **desviación típica de la intensidad** en el intervalo i en frecuencia.
- max_i indica el **máximo de la intensidad** en el intervalo i en frecuencia.

Como el entrenamiento de una RNA es un proceso no determinista, en cada *fold* tendremos que entrenar la RNA varias veces, y promediar los resultados. Para estos experimentos, se ha repetido 30 veces el entrenamiento de la RNA en cada *fold*, devolviendo el resultado promedio de esas 30 ejecuciones.

Para poder evaluar el modelo con mejor rendimiento, como ya se ha dicho antes, utilizaremos como medida el promedio del **F1-Score** en los *folds*. Si hay empate en dicha media, se elegirá el modelo con menor desviación típica de la métrica.

5.1.2. Resultados

Para permitir la reproducibilidad de los experimentos, se utilizó 100 como semilla de generación de números aleatorios.

5.1.2.1 RNA

Para el entrenamiento de las RNA, se han utilizado los siguientes parámetros en común:

- Ratio de aprendizaje: 0,01
- Ratio de patrones para el conjunto de validación: 0,2.
- Máximo número de ciclos (*epochs*) de entrenamiento: 1500.
- Máximo número de ciclos (*epochs*) de entrenamiento sin mejorar el error de validación: 5.
- Algoritmo de optimización: ADAM.
- Función de *loss*: *Binary Cross Entropy*.

El hiperparámetro que hemos variado ha sido la arquitectura de neuronas a utilizar. Utilizamos 8 arquitecturas distintas, donde la arquitectura $[i]$ denota una RNA con una única capa oculta con i neuronas y la arquitectura $[i, j]$ denota una neurona con dos capas ocultas; con i neuronas en la primera capa oculta y j neuronas en la segunda capa oculta.

Se muestran los resultados de la experimentación en la Tabla 2.

5.1.2.2 SVM

Para las máquinas de soporte vectorial hemos utilizado 8 configuraciones distintas de los hiperparámetros de *kernel*, grado del *kernel* (sólo se utiliza en *kernel* polinomial), *gamma* y C .

Se muestran los resultados de la experimentación en la Tabla 3.

Tabla 2: Resultados RNA

Arquitectura	F1-Score	Precisión
[2]	$1,0 \pm 0,0$	$1,0 \pm 0,0$
[4]	$1,0 \pm 0,0$	$1,0 \pm 0,0$
[8]	$1,0 \pm 0,0$	$1,0 \pm 0,0$
[2, 4]	$0,9119 \pm 0,12531$	$0,96487 \pm 0,05054$
[2, 8]	$0,90667 \pm 0,14724$	$0,96524 \pm 0,05412$
[4, 2]	$1,0 \pm 0,0$	$1,0 \pm 0,0$
[4, 4]	$0,99 \pm 0,0225$	$0,99643 \pm 0,00804$
[4, 8]	$0,9621 \pm 0,0974$	$0,97934 \pm 0,05699$

Tabla 3: Resultados SVM

(kernel, grado, gamma, C)	F1-Score	Precisión
(poly, 3, 1, 1)	$1,0 \pm 0,0$	$1,0 \pm 0,0$
(rbf, 3, 1, 1)	$0,93642 \pm 0,07368$	$0,94119 \pm 0,07166$
(sigmoid, 3, 1, 1)	$0,71875 \pm 0,15823$	$0,77143 \pm 0,11289$
(poly, 5, 10, 0,1)	$0,99 \pm 0,03162$	$0,98571 \pm 0,04518$
(rbf, 3, 10, 0,1)	$0,76689 \pm 0,01542$	$0,62214 \pm 0,02026$
(sigmoid, 3, 10, 0,1)	$0,70059 \pm 0,1406$	$0,77768 \pm 0,06262$
(rbf, 3, 0,01, 100)	$1,0 \pm 0,0$	$1,0 \pm 0,0$
(rbf, 3, 100, 0,01)	$0,76689 \pm 0,01542$	$0,62214 \pm 0,02026$

5.1.2.3 Árboles de decisión

Para los árboles de decisión hemos utilizado 6 configuraciones distintas del hiperparámetro de profundidad máxima.

Se muestran los resultados de la experimentación en la Tabla 4.

Tabla 4: Resultados Árbol de decisión

Altura máxima	F1-Score	Precisión
2	$1,0 \pm 0,0$	$1,0 \pm 0,0$
4	$1,0 \pm 0,0$	$1,0 \pm 0,0$
8	$1,0 \pm 0,0$	$1,0 \pm 0,0$
16	$1,0 \pm 0,0$	$1,0 \pm 0,0$
32	$1,0 \pm 0,0$	$1,0 \pm 0,0$
64	$1,0 \pm 0,0$	$1,0 \pm 0,0$

5.1.2.4 kNN

Para el modelo kNN hemos utilizado 6 configuraciones distintas del hiperparámetro de k (número de vecinos más cercanos).

Se muestran los resultados de la experimentación en la Tabla 5.

Tabla 5: Resultados kNN

K	F1-Score	Precisión
2	$1,0 \pm 0,0$	$1,0 \pm 0,0$
3	$1,0 \pm 0,0$	$1,0 \pm 0,0$
5	$1,0 \pm 0,0$	$1,0 \pm 0,0$
8	$1,0 \pm 0,0$	$1,0 \pm 0,0$
13	$1,0 \pm 0,0$	$1,0 \pm 0,0$
21	$0,99091 \pm 0,02875$	$0,99286 \pm 0,02259$

5.1.3. Discusión

Los resultados han sido muy buenos, ya que en la mayoría de casos se alcanza una **precisión** y un **F1-Score** del 100 % o muy alto.

En general, los sistemas se equivocan en muy pocos patrones. Esto se puede deber a que el problema elegido en esta aproximación era excesivamente sencillo para el elevado número de características escogidas, permitiéndonos separar perfectamente los patrones en las dos clases.

En lo referente a las características, por una parte estas han sido correctamente elegidas, ya que alcanzamos una precisión muy alta. Pero por otra parte, el hecho de que algunos sistemas concretos no funcionen tan bien (por ejemplo, algunos SVM), se podría deber al elevado número de características, ya que algunas de ellas pueden ser innecesarias o hasta contraproducentes en este sencillo problema. Una buena estrategia sería el intentar reducir el número de características en futuras aproximaciones, pero hay que tener cuidado, ya que si aumentamos el número de clases, podría darse el caso de haber eliminado una característica necesaria para una correcta clasificación.

En concreto, las características que creemos que son las que producen mejores resultados son las que se refieren a los intervalos en frecuencia de $(0.0, 380.3)$ y $(783.21, 1210.08)$, debido a que es en ellos donde se sitúan las frecuencia de las notas $C4$ y $A5$, respectivamente. Las características que se corresponden a dichos intervalos son m_1 , std_1 , max_1 para el primer intervalo y m_3 , std_3 , max_3 para el segundo intervalo.

Otra característica que podría funcionar sería la frecuencia en la que se alcanza el pico absoluto en intensidad de la señal, o la media de las K frecuencias con mayor intensidad, sin tener en cuenta la división en intervalos. También se podría aumentar el número de intervalos en los que obtener las características, para poder así separar mejor las notas con frecuencias más cercanas.

Todos los algoritmos tienen al menos una configuración con un **F1-Score** de $1,0 \pm 0,0$, por lo que es complicado encontrar uno que sea el mejor.

Podemos destacar la RNA con una arquitectura de una única capa oculta con 2 neuronas, ya que es un modelo muy sencillo y podemos esperar que, cuanto más sencillo sea un modelo, mayor será también su capacidad de generalización.

En la Figura 3 podemos ver un gráfico del entrenamiento de dicha RNA, donde observamos el error cometido en los conjuntos de test, validación y entrenamiento para cada ciclo de entrenamiento. Este se ha realizado utilizando todos los patrones, separando un 20 % para el conjunto de test. Además, se puede ver que se ha producido una parada temprana, ya que el sistema no ha realizado el máximo número de ciclos de entrenamiento (1500 ciclos) y se puede distinguir también como la curva de la gráfica desciende muy rápido. Esto se puede deber a que tenemos un ratio de aprendizaje alto para este problema concreto.

En la Tabla 6 podemos ver una matriz de confusión para la RNA entrenada anteriormente. Las predicciones se hicieron sobre un conjunto de test que supone un 20 % de todos los patrones utilizados. El 80 % de los patrones restantes se utilizó para el entrenamiento de la RNA, ya que el conjunto de entrenamiento no se debería utilizar para realizar predicciones.



Figura 3: Entrenamiento RNA

		Predicc.	
		A5	C4
Real	A5	15	0
	C4	0	15

Tabla 6: Matriz de confusión RNA

Pero aunque se alcance ya un buen resultado con un modelo sencillo como puede ser la RNA anterior, caben destacar los árboles de decisión, que son modelos que pueden ofrecer explicabilidad sobre sus predicciones, además de presentar un entrenamiento determinista, por lo que si tenemos que elegir el mejor modelo, nos decantaríamos por este (en concreto, el de altura máxima de 2, ya que es el más sencillo), ya que presenta también un 100 % de **F1-Score**.

Aunque si deseamos un modelo con una base matemática más fuerte, en vez de un modelo con una base estadística como puede ser un árbol de regresión, utilizar una máquina de soporte vectorial con un *kernel* polinomial de grado 3, y ambos valores de *gamma* y *C* de 1, también sería una buena opción.

Los algoritmos que han funcionado peor han sido ciertas configuraciones de los SVM, en concreto las que utilizan un *kernel* sigmoidal. Entonces, utilizar un *kernel* sigmoidal no parece ofrecer buenos resultados para estos patrones.

5.2. Segunda aproximación

5.2.1. Descripción

Como hemos obtenido resultados muy buenos en la aproximación anterior, aumentaremos la complejidad del problema, es decir, añadiremos más notas a ser clasificadas. Se clasificarán entonces 15 notas y se dispondrá de 1090 patrones para ser utilizados por el sistema.

Las notas que vamos a clasificar son: $C1$, $C2$, $C3$, $C4$, $C5$, $C6$, $C7$, $C8$, $A1$, $A2$, $A3$, $A4$, $A5$, $A6$ y $A7$.

Se puede ver algunos ejemplos de los *samples* que vamos a utilizar, con su señal en el dominio del tiempo y en el dominio de la frecuencia, en las Figuras 4a, 4b, 5a y 5b.




Figura 4

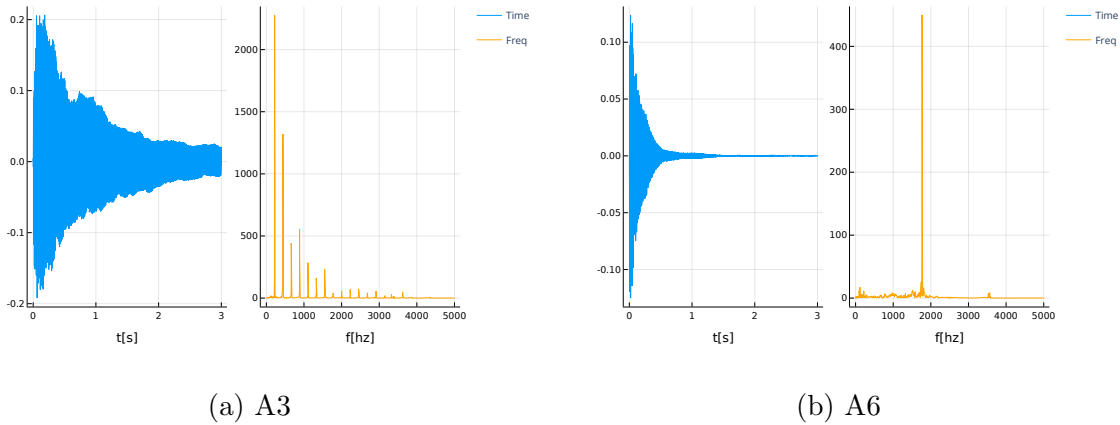


Figura 5

Como hemos aumentado mucho el número de clases a clasificar, decidimos aumentar también el número de características para lograr una correcta diferenciación entre las clases que sean más similares.

En concreto, añadiremos las siguientes características:

- **Frecuencia en la que se alcanza la máxima intensidad** en cada uno de los 10 intervalos que ya se especificaron en la aproximación anterior.

No se producen cambios sobre las características que fueron incorporadas en la aproximación anterior.

Para el preprocesado de los datos, utilizaremos, como se mencionó en la aproximación anterior, una normalización de media cero. Así, obtuvimos para cada característica, la media y la desviación típica. Se muestran dichos datos en las Tablas 7 y 8.

Tabla 7: Parámetros de normalización (I)

Característica	Media	Desviación Típica
E	0,0050883736	0,0088912
zero-crossing	3743,606	5035,344
m ₁	15,578591	18,397396
m ₂	11,147778	9,179351
m ₃	9,6564455	9,295277
m ₄	4,0943613	4,225765
m ₅	3,6645029	4,699565
m ₆	1,0346977	1,3888823
m ₇	0,71540374	1,0062366
m ₈	0,68384236	1,307346
m ₉	0,38978294	0,8350492
m ₁₀	0,44757652	1,4078437
std ₁	49,61187	74,658005
std ₂	39,12518	41,206196
std ₃	29,023785	34,23634
std ₄	8,560635	11,001557
std ₅	9,463276	12,920476
std ₆	1,5626754	2,6529887
std ₇	1,6301519	2,8170295
std ₈	1,2500806	2,295387
std ₉	0,5342404	0,98041487
std ₁₀	0,7347808	2,2108128
max ₁	944,37256	1596,2578
max ₂	748,07245	844,44037
max ₃	442,8393	524,42633
max ₄	130,52594	192,10622
max ₅	129,60143	179,40135
max ₆	19,159048	36,38486
max ₇	22,589241	40,29418
max ₈	13,267355	21,899231
max ₉	5,3473926	10,327133
max ₁₀	5,520794	13,594501

Tabla 8: Parámetros de normalización (II)

Característica	Media	Desviación Típica
max-freq ₁	174,89925	87,058235
max-freq ₂	521,6259	125,11409
max-freq ₃	961,683	100,904564
max-freq ₄	1394,9509	126,07898
max-freq ₅	1897,9567	174,84656
max-freq ₆	2353,7712	191,61922
max-freq ₇	2791,1377	166,82562
max-freq ₈	3426,2026	169,13255
max-freq ₉	4093,2415	226,97453
max-freq ₁₀	4583,3877	193,1689

Donde:

- E indica la **energía de la señal**.
- m_i indica la **media de la intensidad** en el intervalo i en frecuencia.
- std_i indica la **desviación típica de la intensidad** en el intervalo i en frecuencia.
- max_i indica el **máximo de la intensidad** en el intervalo i en frecuencia.
- $max-freq_i$ indica la **frecuencia donde se alcanza el máximo de intensidad** en el intervalo i en frecuencia.

Para estos experimentos se ha repetido 20 veces el entrenamiento de la RNA en cada *fold*, devolviendo el resultado promedio de esas 20 ejecuciones.

Para poder evaluar el modelo con mejor rendimiento, como ya se ha dicho antes, utilizaremos como medida el promedio del **F1-Score** en los *folds*. Si hay empate en dicha media, se elegirá el modelo con menor desviación típica de la métrica.

5.2.2. Resultados

Para permitir la reproducibilidad de los experimentos, se utilizó 100 como semilla de generación de números aleatorios.

5.2.2.1 RNA

Para el entrenamiento de las RNA, se han utilizado los siguientes parámetros en común:

- Ratio de aprendizaje: 0,01
- Ratio de patrones para el conjunto de validación: 0,2.
- Máximo número de ciclos (*epochs*) de entrenamiento: 1500.
- Máximo número de ciclos (*epochs*) de entrenamiento sin mejorar el error de validación: 5.
- Algoritmo de optimización: ADAM.
- Función de *loss*: *Cross Entropy*.

El hiperparámetro que hemos variado ha sido la arquitectura de neuronas a utilizar. Utilizamos 8 arquitecturas distintas, donde la arquitectura $[i]$ denota una RNA con una única capa oculta con i neuronas y la arquitectura $[i, j]$ denota una neurona con dos capas ocultas; con i neuronas en la primera capa oculta y j neuronas en la segunda capa oculta.

Se muestran los resultados de la experimentación en la Tabla 9

Tabla 9: Resultados RNA

Arquitectura	F1-Score	Precisión
[8]	$0,92977 \pm 0,01923$	$0,95523 \pm 0,0131$
[16]	$0,96092 \pm 0,0163$	$0,97591 \pm 0,0112$
[32]	$0,96305 \pm 0,01805$	$0,97745 \pm 0,01137$
[8, 8]	$0,87808 \pm 0,01593$	$0,92368 \pm 0,00628$
[16, 4]	$0,76012 \pm 0,03119$	$0,8518 \pm 0,0233$
[16, 8]	$0,92264 \pm 0,02515$	$0,95168 \pm 0,01708$
[32, 16]	$0,9506 \pm 0,01989$	$0,97044 \pm 0,01033$
[32, 32]	$0,95122 \pm 0,02256$	$0,97004 \pm 0,013$

5.2.2.2 SVM

Para las máquinas de soporte vectorial hemos utilizado 8 configuraciones distintas de los hiperparámetros de *kernel*, grado del *kernel* (sólo se utiliza en *kernel* polinomial), *gamma* y *C*.

Se muestran los resultados de la experimentación en la Tabla 10

Tabla 10: Resultados SVM

(kernel, grado, gamma, C)	F1-Score	Precisión
(poly, 3, 1, 1)	$0,97261 \pm 0,02358$	$0,98158 \pm 0,01438$
(rbf, 3, 1, 1)	$0,67559 \pm 0,04297$	$0,69947 \pm 0,05196$
(sigmoid, 3, 1, 1)	$0,28516 \pm 0,03747$	$0,3575 \pm 0,03929$
(poly, 3, 10, 0,1)	$0,97619 \pm 0,02456$	$0,98415 \pm 0,01345$
(rbf, 3, 10, 0,1)	$0,01607 \pm 0,00059$	$0,13703 \pm 0,00568$
(sigmoid, 3, 10, 0,1)	$0,23652 \pm 0,03974$	$0,33481 \pm 0,04109$
(rbf, 3, 0,01, 100)	$0,97415 \pm 0,02285$	$0,98444 \pm 0,0122$
(poly, 3, 100, 0,001)	$0,9678 \pm 0,03578$	$0,97987 \pm 0,01547$

5.2.2.3 Árboles de decisión

Para los árboles de decisión hemos utilizado 6 configuraciones distintas del hiperparámetro de profundidad máxima.

Se muestran los resultados de la experimentación en la Tabla 11

Tabla 11: Resultados Árbol de decisión

Altura máxima	F1-Score	Precisión
4	$0,44767 \pm 0,00668$	$0,66703 \pm 0,01287$
8	$0,86809 \pm 0,02258$	$0,92653 \pm 0,01909$
16	$0,96505 \pm 0,02104$	$0,9725 \pm 0,0143$
32	$0,96786 \pm 0,01849$	$0,97302 \pm 0,01609$
64	$0,97438 \pm 0,01244$	$0,97779 \pm 0,0102$
128	$0,97415 \pm 0,0161$	$0,9779 \pm 0,01186$
256	$0,9672 \pm 0,02388$	$0,97452 \pm 0,0172$

5.2.2.4 kNN

Para el modelo kNN hemos utilizado 6 configuraciones distintas del hiperparámetro de k (número de vecinos más cercanos).

Se muestran los resultados de la experimentación en la tabla 12

Tabla 12: Resultados kNN

K	F1-Score	Precisión
2	$0,95086 \pm 0,01526$	$0,97073 \pm 0,0088$
3	$0,9323 \pm 0,03125$	$0,95942 \pm 0,0156$
5	$0,90323 \pm 0,03494$	$0,94503 \pm 0,01712$
8	$0,86641 \pm 0,03906$	$0,93135 \pm 0,0199$
13	$0,84065 \pm 0,02462$	$0,90985 \pm 0,01911$
21	$0,80344 \pm 0,03804$	$0,88737 \pm 0,02667$

5.2.3. Discusión

En general los resultados son muy buenos, ya que hay varios modelos con un alto F1-Score. El modelo que mejor funciona es un SVM con función de *kernel* polinomial de grado 3, con un *gamma* y *C* de 10 y 0,1, respectivamente.

Este modelo tiene un F1-Score de $0,97619 \pm 0,02456$, con una precisión de $0,98415 \pm 0,01345$ en los *folds*. De este resultado podemos concluir que nuestro sistema funciona muy bien, ya que clasificar 15 notas es un problema relativamente complejo.

Cabe destacar modelos como la RNA con una única capa oculta de 32 neuronas; el SVM con *kernel* de base radial, con los parámetros de *gamma* 0,01 y de *C* 100; un árbol de decisión con altura máxima de 64; y un modelo kNN con un *k* de 2. Estos modelos también presentan muy buenos resultados, aunque no los mejores.

El modelo con peor rendimiento es un SVM con *kernel* de base radial con *gamma* y *C* de 10 y 0,1, respectivamente. Esta configuración del modelo un *F1-Score* de tan solo $0,01607 \pm 0,00059$, desconociendo realmente a qué se debe realmente este tan bajo resultado.

En cuanto a las características, creemos que fue un acierto añadir la frecuencia a la que se encuentra el pico de intensidad en cada intervalo, ya que es una característica muy representativa de la señal y que sirve para diferenciar mejor las notas. Sin estas nuevas características (y habiendo hecho las pruebas), los resultados no serían tan buenos.

El problema que podemos observar en la matriz de confusión (Tabla 13) para el mejor sistema es que el sistema se equivoca en las notas más cercanas, como pueden ser *A1*, *A2*, *C1* y *C2*; notas que tienen una frecuencia muy similar y se encuentran en el primer intervalo, $(0.0, 380.3)$.

Para poder diferenciar mejor entre estas notas (y entre futuras notas que puedan ser similares entre ellas), sería una buena opción que se aumentase el número de intervalos a dividir las frecuencias, para así poder diferenciar de mejor manera dichas notas.

		Predicc.														
		C1	C2	C3	C4	C5	C6	C7	C8	A1	A2	A3	A4	A5	A6	A7
Real	C1	3	0	0	0	0	0	0	0	1	0	0	0	0	0	0
	C2	1	6	1	0	0	0	0	0	0	0	0	0	0	0	0
	C3	0	0	9	0	0	0	0	0	0	0	0	0	0	0	0
	C4	0	0	1	18	0	0	0	0	0	0	0	0	0	0	0
	C5	0	0	0	0	25	0	0	0	0	0	0	0	0	0	0
	C6	0	0	0	0	0	10	0	0	0	0	0	0	0	0	0
	C7	0	0	0	0	0	0	23	0	0	0	0	0	0	0	0
	C8	0	0	0	0	0	0	0	19	0	0	0	0	0	0	1
	A1	0	0	0	0	0	0	0	0	16	0	0	0	0	0	0
	A2	0	0	0	0	0	0	0	0	1	15	0	0	0	0	0
	A3	0	0	0	3	0	0	0	0	0	0	12	0	0	0	0
	A4	0	0	0	0	0	0	0	0	0	0	0	13	0	0	0
	A5	0	0	0	0	0	0	0	0	0	0	0	0	15	0	0
	A6	0	0	0	0	0	0	0	0	0	0	0	0	0	15	1
	A7	0	0	0	0	0	0	0	0	0	0	0	0	0	0	9

Tabla 13: Matriz de confusión mejor modelo

5.3. Tercera aproximación


5.3.1. Descripción

Como hemos obtenido resultados muy buenos en la aproximación anterior, seguiremos aumentando la complejidad del problema, es decir, añadiremos más notas a ser clasificadas. Serán un total de 50 notas a clasificar, y se dispondrá de 3194 patrones para ser utilizados por los modelos.


Las notas que vamos a clasificar son: $C1, C2, C3, C4, C5, C6, C7, C8, A1, A2, A3, A4, A5, A6, A7, B1, B2, B3, B4, B5, B6, B7, D1, D2, D3, D4, D5, D6, D7, E1, E2, E3, E4, E5, E6, E7, F1, F2, F3, F4, F5, F6, F7, G1, G2, G3, G4, G5, G6$ y $G7$.

Se pueden ver algunos ejemplos de estas notas, en el dominio del tiempo y de la frecuencia, en las Figuras 6a, 6b, 7a y 7b.

Como en esta aproximación aumentamos mucho el número de clases a clasificar (50 en total), nos parece buena opción aumentar también las características utilizadas, pero desde un enfoque diferente a la anterior aproximación. Lo que haremos será aumentar el número de intervalos a dividir el dominio de la frecuencia; de 10 intervalos que teníamos anteriormente, a 30 intervalos. De esta manera, esperamos que se puede clasificar mejor notas que tengan frecuencias muy cercanas, además de repartir mejor el número de notas que coinciden en cada intervalo.

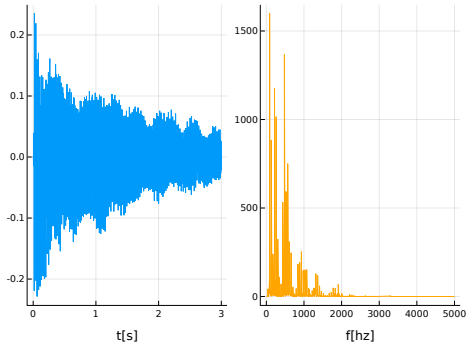


(a) D1




(b) E1

Figura 6



(a) F1



(b) G1

Figura 7

En concreto, los intervalos de frecuencias que utilizaremos serán los siguientes:

$(0.0, 63.845), (63.845, 131.486), (131.486, 203.149), (203.149, 279.074), (279.074, 359.513), (359.513, 444.735), (444.735, 535.025), (535.025, 630.684), (630.684, 732.032), (732.032, 839.405), (839.405, 953.163), (953.163, 1073.686), (1073.686, 1201.376), (1201.376, 1336.658), (1336.658, 1479.984), (1479.984, 1631.833), (1631.833, 1792.712), (1792.712, 1963.157), (1963.157, 2143.737), (2143.737, 2335.055), (2335.055, 2537.749), (2537.749, 2752.496), (2752.496, 2980.013), (2980.013, 3221.059), (3221.059, 3476.437), (3476.437, 3747.002), (3747.002, 4033.655), (4033.655, 4337.353), (4337.353, 4659.11)$ y $(4659.11, 5000.0)$

Para el preprocesado de los datos, utilizaremos, como se mencionó en aproximaciones anteriores, una normalización de media cero. Así, obtuvimos para cada característica, la media y la desviación típica. Se muestran dichos datos en las Tablas 14, 15 16 y 17.

Tabla 14: Parámetros de normalización (I)

Característica	Media	Desviación Típica
E	0,0054126005	0,009019938
zero-crossing	3397,5913	4540,8813
m ₁	2,5406487	5,2477403
m ₂	20,31295	34,20369
m ₃	18,736494	33,777767
m ₄	19,506176	27,648252
m ₅	17,283388	26,778984
m ₆	14,071337	21,961533
m ₇	15,653144	21,659325
m ₈	7,2894015	11,942419
m ₉	10,673911	22,342806
m ₁₀	8,886631	17,860262
m ₁₁	8,768464	14,431124
m ₁₂	9,399654	13,1116905
m ₁₃	7,141891	16,054686
m ₁₄	5,671832	9,146762
m ₁₅	4,4691596	7,688136
m ₁₆	4,622483	7,50842
m ₁₇	2,8246067	5,453456
m ₁₈	2,1192815	3,5254076
m ₁₉	3,2075806	5,558346
m ₂₀	1,3101652	2,2760432
m ₂₁	1,5997506	4,51931
m ₂₂	1,4330753	3,7737772
m ₂₃	0,9662523	2,9858894
m ₂₄	0,79353756	1,8264828
m ₂₅	0,48343834	0,8716932
m ₂₆	0,6009706	1,4477166
m ₂₇	0,3706837	0,93128383
m ₂₈	0,41856125	1,3392309
m ₂₉	0,38214317	1,6580197
m ₃₀	0,13477807	0,25888646

Tabla 15: Parámetros de normalización (II)

Característica	Media	Desviación Típica
std ₁	3,777772	9,5573845
std ₂	43,746407	101,179634
std ₃	44,765743	106,52451
std ₄	44,928486	86,98192
std ₅	36,79204	74,466835
std ₆	34,05622	69,12505
std ₇	35,642204	58,005997
std ₈	14,239829	31,195595
std ₉	20,148722	46,739002
std ₁₀	18,305641	41,97697
std ₁₁	15,096799	33,64003
std ₁₂	17,944155	31,481377
std ₁₃	14,973824	42,54836
std ₁₄	10,101966	21,576153
std ₁₅	7,4685116	17,61445
std ₁₆	7,9542217	17,202675
std ₁₇	5,18349	11,849964
std ₁₈	2,358577	5,2823844
std ₁₉	6,350091	12,173027
std ₂₀	1,757622	4,281193
std ₂₁	2,7778556	8,633124
std ₂₂	2,4016538	6,636576
std ₂₃	1,6487495	5,640244
std ₂₄	1,3393545	3,0001454
std ₂₅	0,606615	1,4506007
std ₂₆	0,9203455	2,2596686
std ₂₇	0,4674074	1,0911392
std ₂₈	0,64302534	2,1712365
std ₂₉	0,45122066	1,628174
std ₃₀	0,19327588	0,4538704

Tabla 16: Parámetros de normalización (III)

Característica	Media	Desviación Típica
max ₁	33,78178	108,59057
max ₂	448,6926	1190,1057
max ₃	473,44827	1207,2843
max ₄	464,8955	994,3883
max ₅	362,47415	770,89215
max ₆	343,7377	698,5618
max ₇	339,793	571,1343
max ₈	146,53598	331,86856
max ₉	187,07274	410,4047
max ₁₀	172,76352	362,9538
max ₁₁	142,42677	321,43628
max ₁₂	170,99661	295,21555
max ₁₃	140,03787	364,36176
max ₁₄	98,230865	208,93227
max ₁₅	68,81298	154,13226
max ₁₆	74,12923	160,24773
max ₁₇	51,78036	117,74015
max ₁₈	20,73961	55,032047
max ₁₉	55,946613	99,87239
max ₂₀	16,036867	44,92402
max ₂₁	23,404562	60,15183
max ₂₂	19,944548	46,585274
max ₂₃	14,242097	44,026596
max ₂₄	11,504292	23,90699
max ₂₅	5,2844114	13,773306
max ₂₆	7,49625	17,74915
max ₂₇	3,6148624	8,03344
max ₂₈	4,8835807	14,053778
max ₂₉	3,2500324	9,766679
max ₃₀	1,6198401	3,8292391

Tabla 17: Parámetros de normalización (IV)

Característica	Media	Desviación Típica
max-freq ₁	35,377235	14,779791
max-freq ₂	109,41023	14,310052
max-freq ₃	157,08893	22,204115
max-freq ₄	237,34592	25,370153
max-freq ₅	310,14645	24,312443
max-freq ₆	403,7519	27,410894
max-freq ₇	489,3408	23,016937
max-freq ₈	584,6093	31,939516
max-freq ₉	672,22675	27,801172
max-freq ₁₀	781,4551	30,98548
max-freq ₁₁	904,9106	33,565907
max-freq ₁₂	1004,27	35,98437
max-freq ₁₃	1136,5785	49,034184
max-freq ₁₄	1269,4824	45,24625
max-freq ₁₅	1409,3927	50,92556
max-freq ₁₆	1535,1046	41,005337
max-freq ₁₇	1704,3861	49,30979
max-freq ₁₈	1873,1862	58,287815
max-freq ₁₉	2052,2415	60,40939
max-freq ₂₀	2217,6611	66,80756
max-freq ₂₁	2417,3076	57,010002
max-freq ₂₂	2638,4033	58,779163
max-freq ₂₃	2857,4375	74,33377
max-freq ₂₄	3086,9392	80,97323
max-freq ₂₅	3342,3274	80,32275
max-freq ₂₆	3589,7864	78,69773
max-freq ₂₇	3879,9844	98,408936
max-freq ₂₈	4168,601	103,71468
max-freq ₂₉	4459,1206	91,55003
max-freq ₃₀	4837,6816	100,40303

Donde:

- E indica la **energía de la señal**.
- m_i indica la **media de la intensidad** en el intervalo i en frecuencia.
- std_i indica la **desviación típica de la intensidad** en el intervalo i en frecuencia.
- max_i indica el **máximo de la intensidad** en el intervalo i en frecuencia.
- $max-freq_i$ indica la **frecuencia donde se alcanza el máximo de intensidad** en el intervalo i en frecuencia.

Para estos experimentos se ha repetido 20 veces el entrenamiento de la RNA en cada *fold*, devolviendo el resultado promedio de esas 20 ejecuciones.

Para poder evaluar el modelo con mejor rendimiento, como ya se ha dicho anteriormente, utilizaremos como medida el promedio del **F1-Score** en los *folds*. Si hay empate en dicha media, se elegirá el modelo con menor desviación típica de la métrica.

5.3.2. Resultados

Para permitir la reproducibilidad de los experimentos, se utilizó *100* como semilla de generación de números aleatorios.

5.3.2.1 RNA

Para el entrenamiento de las RNA, se han utilizado los siguientes parámetros en común:

- Ratio de aprendizaje: 0,01
- Ratio de patrones para el conjunto de validación: 0,2.
- Máximo número de ciclos (*epochs*) de entrenamiento: 1500.
- Máximo número de ciclos (*epochs*) de entrenamiento sin mejorar el error de validación: 5.
- Algoritmo de optimización: ADAM.
- Función de *loss*: *Cross Entropy*.

El hiperparámetro que hemos variado ha sido la arquitectura de neuronas a utilizar. Utilizamos 8 arquitecturas distintas, donde la arquitectura $[i]$ denota una RNA con una única capa oculta con i neuronas y la arquitectura $[i, j]$ denota una neurona con dos capas ocultas; con i neuronas en la primera capa oculta y j neuronas en la segunda capa oculta.

Se muestran los resultados de la experimentación en la Tabla 18.

Tabla 18: Resultados RNA

Arquitectura	F1-Score	Precisión
[16]	$0,95148 \pm 0,00551$	$0,96105 \pm 0,00471$
[32]	$0,98759 \pm 0,00345$	$0,9897 \pm 0,00221$
[64]	$0,99345 \pm 0,00309$	$0,99428 \pm 0,00162$
[128]	$0,99293 \pm 0,00258$	$0,99424 \pm 0,00123$
[256]	$0,99269 \pm 0,00345$	$0,9936 \pm 0,00299$
[512]	$0,98348 \pm 0,0061$	$0,98603 \pm 0,00423$
[64, 64]	$0,98322 \pm 0,00373$	$0,98554 \pm 0,00292$
[64, 128]	$0,9818 \pm 0,00226$	$0,98428 \pm 0,00227$

5.3.2.2 SVM

Para las máquinas de soporte vectorial hemos utilizado 8 configuraciones distintas de los hiperparámetros de *kernel*, grado del *kernel* (sólo se utiliza en *kernel* polinomial), *gamma* y *C*.

Se muestran los resultados de la experimentación en la Tabla 19.

Tabla 19: Resultados SVM

(kernel, grado, gamma, C)	F1-Score	Precisión
(poly, 3, 1, 1)	$0,99264 \pm 0,0053$	$0,99382 \pm 0,00422$
(rbf, 3, 1, 1)	$0,10019 \pm 0,01854$	$0,11513 \pm 0,0161$
(sigmoid, 3, 1, 1)	$0,13051 \pm 0,02229$	$0,20283 \pm 0,02546$
(poly, 3, 10, 0,1)	$0,99113 \pm 0,00724$	$0,99314 \pm 0,00464$
(rbf, 3, 10, 0,1)	$0,00179 \pm 7,0e - 5$	$0,04673 \pm 0,00189$
(sigmoid, 3, 10, 0,1)	$0,10752 \pm 0,01502$	$0,18363 \pm 0,01528$
(rbf, 3, 0,01, 100)	$0,99504 \pm 0,00411$	$0,99563 \pm 0,00257$
(poly, 3, 100, 0,001)	$0,99257 \pm 0,00408$	$0,99379 \pm 0,00278$

5.3.2.3 Árboles de decisión

Para los árboles de decisión hemos utilizado 6 configuraciones distintas del hiperparámetro de profundidad máxima.

Se muestran los resultados de la experimentación en la Tabla 20.

5.3.2.4 kNN

Para el modelo kNN hemos utilizado 6 configuraciones distintas del hiperparámetro de k (número de vecinos más cercanos).

Se muestran los resultados de la experimentación en la tabla 21.

Tabla 20: Resultados Árbol de decisión

Altura máxima	F1-Score	Precisión
4	$0,09189 \pm 0,01043$	$0,17819 \pm 0,0157$
8	$0,3111 \pm 0,01697$	$0,42453 \pm 0,01404$
16	$0,71777 \pm 0,04105$	$0,79892 \pm 0,03264$
32	$0,94074 \pm 0,01447$	$0,94584 \pm 0,01159$
64	$0,94887 \pm 0,01332$	$0,95193 \pm 0,01202$
128	$0,95088 \pm 0,00891$	$0,9555 \pm 0,00573$
256	$0,95003 \pm 0,00775$	$0,95269 \pm 0,0076$

Tabla 21: Resultados kNN

K	F1-Score	Precisión
2	$0,98683 \pm 0,00434$	$0,98845 \pm 0,00303$
3	$0,98153 \pm 0,00991$	$0,98636 \pm 0,00479$
5	$0,98086 \pm 0,00835$	$0,98617 \pm 0,00599$
8	$0,97161 \pm 0,01603$	$0,98024 \pm 0,01049$
13	$0,96203 \pm 0,01287$	$0,97342 \pm 0,00864$
21	$0,95836 \pm 0,00902$	$0,96928 \pm 0,00517$

5.3.3. Discusión

Los resultados de esta iteración son muy buenos, ya que hemos aumentado en gran medida el número de notas a clasificar y hemos conseguido varios modelos con más de un 99 % de F1-Score y precisión.

En concreto, el modelo que mejor funciona es un SVM con un *kernel* de base radial y con valores de *gamma* y *C* de 0,01 y 100, respectivamente. Este modelo alcanzó un F1-Score de $0,99594 \pm 0,00411$ y una precisión de $0,99563 \pm 0,00257$, unos valores muy altos y que indican que el sistema funciona muy bien.

Caben destacar también modelos que alcanzan un rendimiento parecido, como puede ser un SVM con un *kernel* polinomial de grado 3, con ambos valores de *gamma* y *C* de 1, además de una RNA con una única capa oculta con 32 neuronas.

En contra, el modelo que peor rendimiento presenta es un SVM con un *kernel* de base radial, con valores de *gamma* y *C* de 10 y 0,1, respectivamente. Cabe destacar que este modelo es similar al modelo que presenta el mejor rendimiento, siendo lo único que cambia los parámetros de *gamma* y *C*. Es notable ver que un ligero cambio en estos dos parámetros puede producir que un sistema pase de ser muy malo, a ser muchísimo mejor.

Como hemos podido ver, los resultados son muy buenos en general, pero algunos de estos sistemas tienen un problema (principalmente las RNAs), y es que el tiempo de

En la matriz de confusión de la Tabla 22 hemos omitido por razones de tamaño las filas y las columnas donde el sistema no se confunde, a excepción de las 5 primeras y las 8 ultimas para definir el rango de notas de esta aproximación y su patrón diagonal de aciertos. Al igual que anteriores aproximaciones podemos destacar que los fallos son entre notas con frecuencias muy parecidas como pueden ser $G1(48,99\text{ Hz})$ y $A1(55\text{ Hz})$ o $G1(48,99\text{ Hz})$ y $E2(82,40\text{ Hz})$.

		C1	C2	C3	C4	C5	C6	C7	C8	A1	A2	...	B4	B5	B6	B7	D1	...	Predicc.										F6	F7	G1	G2	G3	G4	G5	G6	G7
	C1	7	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	E1	E2	E3	...	E6	E7	F1	F2	F3	...	0	0	0	0	0	0	0	0	0
	C2	0	7	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C3	0	0	0	11	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C4	0	0	0	15	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C5	0	0	0	0	32	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
																		
	B5	0	0	0	0	0	0	0	0	0	0	...	0	14	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	B6	0	0	0	0	0	0	0	0	1	0	...	0	0	18	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	B7	0	0	0	0	0	0	0	0	0	0	...	0	0	0	14	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
																		
	E7	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	17	0	0	0	...	0	0	0	0	0	0	0	0	0
	F1	0	0	0	0	0	0	0	0	0	2	...	0	0	0	0	0	...	0	0	0	...	0	0	4	0	0	...	0	0	0	0	0	0	0	0	0
	F2	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	12	0	...	0	0	0	0	0	0	0	0	0
																		
	F7	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	15	0	0	0	0	0	0	0
	G1	0	0	0	0	0	0	0	0	0	3	...	0	0	0	0	0	...	0	1	0	...	0	0	0	0	0	...	0	0	5	0	0	0	0	0	
	G2	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	12	0	0	0	0	
	G3	0	0	0	0	0	0	0	0	0	2	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	5	0	0	0	
	G4	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	11	0	0	
	G5	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	10	0	0
	G6	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	7	0
	G7	0	0	0	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	17

33

5.4. Cuarta aproximación

5.4.1. Descripción

Como seguimos obteniendo resultados muy satisfactorios, en esta aproximación aumentaremos a 85 las notas a clasificar y dispondremos de 5406 patrones para ser utilizados por los modelos.

Las notas que vamos a clasificar constituyen el total de notas del piano, por lo que en esta aproximación será donde veamos cómo de bien se comporta nuestro sistema ante el problema completo. En concreto, las nuevas notas que añadimos son los sostenidos de cada escala. Estos presentan un especial problema, ya que solo están a distancia de un semitono con respecto a la nota original, resultando en frecuencias muy cercanas.

Para intentar paliar este inconveniente, decidimos añadir dos nuevas características que son:

- **Intensidad absoluta máxima:** Que determina la intensidad máxima que alcanza la señal en frecuencia.
- **Frecuencia absoluta máxima:** Que determina la frecuencia absoluta máxima que toma la señal.

Así, las notas que vamos a clasificar son: *A1, A2, A3, A4, A5, A6, A7, A#1, A#2, A#3, A#4, A#5, A#6, A#7, B1, B2, B3, B4, B5, B6, B7, C1, C2, C3, C4, C5, C6, C7, C8, C#1, C#2, C#3, C#4, C#5, C#6, C#7, C8, D1, D2, D3, D4, D5, D6, D7, D#1, D#2, D#3, D#4, D#5, D#6, D#7, E1, E2, E3, E4, E5, E6, E7, F1, F2, F3, F4, F5, F6, F7, F#1, F#2, F#3, F#4, F#5, F#6, F#7, G1, G2, G3, G4, G5, G6, G7, G#1, G#2, G#3, G#4, G#5, G#6 y G#7.*

Se pueden ver algunos ejemplos de estas notas, en el dominio del tiempo y de la frecuencia, en las Figuras 8a, 8b, 9a y 9b.



Figura 8



Figura 9

Se muestran a continuación los parámetros de normalización (volveremos a utilizar media cero) para cada característica en las Tablas 32, 33 25 y 26.

Tabla 23: Parámetros de normalización (I)

Característica	Media	Desviación Típica
E	0,005290622	0,009127998
zero-crossing	3317,7852	4477,6226
abs-max	1445,9364	1557,9128
abs-max-freq	980,58826	1027,9849
m ₁	2,5213237	4,892542
m ₂	19,776129	34,19082
m ₃	18,500994	33,448643
m ₄	20,293629	28,46877
m ₅	15,832674	24,200994
m ₆	13,741416	21,621166
m ₇	13,71829	20,745993
m ₈	10,299257	17,33558
m ₉	9,490465	18,469109
m ₁₀	9,750799	19,446434
m ₁₁	9,340946	13,882007
m ₁₂	7,7851214	11,177626
m ₁₃	6,734947	13,808262
m ₁₄	5,5433474	8,790224
m ₁₅	4,2768292	6,906526
m ₁₆	4,459063	7,8797054
m ₁₇	2,9236934	5,253287
m ₁₈	2,6162808	5,561383
m ₁₉	2,5326357	4,6802435
m ₂₀	1,656642	4,287465
m ₂₁	1,6121823	4,2043204
m ₂₂	1,1647563	3,044825
m ₂₃	0,87163603	2,4234502
m ₂₄	0,83163273	2,1765046
m ₂₅	0,61601394	1,4981358
m ₂₆	0,5027224	1,2157471
m ₂₇	0,44925115	1,2129601
m ₂₈	0,3179743	1,0582143
m ₂₉	0,30106485	1,2961926
m ₃₀	0,12668554	0,24906345

Tabla 24: Parámetros de normalización (II)

Característica	Media	Desviación Típica
std ₁	3,7071	8,894764
std ₂	41,93409	100,38277
std ₃	41,496273	100,46413
std ₄	50,62945	97,251366
std ₅	32,27192	66,25659
std ₆	31,772036	64,703476
std ₇	30,200518	56,291985
std ₈	24,33468	49,075897
std ₉	17,22069	40,07678
std ₁₀	21,47563	49,664173
std ₁₁	16,356256	32,295124
std ₁₂	13,809475	27,013056
std ₁₃	13,494098	35,255543
std ₁₄	9,511233	19,50926
std ₁₅	7,4176326	16,4802
std ₁₆	7,555132	18,873085
std ₁₇	5,6317873	11,938161
std ₁₈	3,8923404	10,900163
std ₁₉	4,617325	10,1336155
std ₂₀	2,5670214	8,334569
std ₂₁	2,7792637	7,7385535
std ₂₂	1,8842899	5,510914
std ₂₃	1,4960651	4,586712
std ₂₄	1,4450701	3,7847013
std ₂₅	0,90402246	2,5514781
std ₂₆	0,7006507	1,8386049
std ₂₇	0,6376248	1,6106461
std ₂₈	0,48451066	1,7358224
std ₂₉	0,38622695	1,3208534
std ₃₀	0,18503572	0,458966

Tabla 25: Parámetros de normalización (III)

Característica	Media	Desviación Típica
max ₁	33,110157	99,81226
max ₂	415,37152	1154,7861
max ₃	422,34433	1112,5609
max ₄	536,3476	1134,9387
max ₅	317,401	698,8781
max ₆	316,10635	644,3593
max ₇	293,7506	569,4251
max ₈	239,86774	471,9059
max ₉	162,63959	375,88123
max ₁₀	207,69164	447,70316
max ₁₁	156,60005	323,31445
max ₁₂	132,93877	264,18588
max ₁₃	129,61961	310,57278
max ₁₄	90,64936	186,6918
max ₁₅	72,60896	163,45084
max ₁₆	68,42438	165,54524
max ₁₇	55,859993	115,98919
max ₁₈	35,653084	97,61015
max ₁₉	40,517826	84,012886
max ₂₀	22,404512	67,51314
max ₂₁	23,722889	55,782883
max ₂₂	16,067352	41,516422
max ₂₃	13,351332	36,865856
max ₂₄	11,76221	26,125443
max ₂₅	7,4373846	19,201763
max ₂₆	5,7013874	14,642168
max ₂₇	4,8674684	10,794909
max ₂₈	3,8479474	11,645865
max ₂₉	2,9212744	8,312529
max ₃₀	1,5820836	3,9503338

Tabla 26: Parámetros de normalización (IV)

Característica	Media	Desviación Típica
max-freq ₁	34,545124	14,418398
max-freq ₂	108,99156	14,543035
max-freq ₃	157,66272	22,50655
max-freq ₄	237,14865	26,168978
max-freq ₅	308,71167	24,800741
max-freq ₆	404,29333	26,971804
max-freq ₇	488,65253	23,474133
max-freq ₈	584,63116	31,848839
max-freq ₉	671,4978	29,488453
max-freq ₁₀	784,3489	33,213223
max-freq ₁₁	905,13873	34,916843
max-freq ₁₂	1005,73865	39,89346
max-freq ₁₃	1136,8329	46,666904
max-freq ₁₄	1264,4369	42,46175
max-freq ₁₅	1412,9193	49,629932
max-freq ₁₆	1537,3774	44,49866
max-freq ₁₇	1700,5549	47,24032
max-freq ₁₈	1871,9404	52,69005
max-freq ₁₉	2058,1985	61,4545
max-freq ₂₀	2220,4458	62,312325
max-freq ₂₁	2422,4363	62,446247
max-freq ₂₂	2629,6775	65,41493
max-freq ₂₃	2861,094	72,73729
max-freq ₂₄	3082,9204	77,84288
max-freq ₂₅	3346,068	74,768135
max-freq ₂₆	3592,8464	87,46203
max-freq ₂₇	3867,4265	90,45616
max-freq ₂₈	4171,0786	102,07654
max-freq ₂₉	4471,467	94,344215
max-freq ₃₀	4826,714	102,89994

Donde:

- E indica la **energía de la señal**.
- m_i indica la **media de la intensidad** en el intervalo i en frecuencia.
- std_i indica la **desviación típica de la intensidad** en el intervalo i en frecuencia.
- max_i indica el **máximo de la intensidad** en el intervalo i en frecuencia.
- $max-freq_i$ indica la **frecuencia donde se alcanza el máximo de intensidad** en el intervalo i en frecuencia.

Para estos experimentos se volvió a repetir 20 veces el entrenamiento de la RNA en cada *fold*, devolviendo el resultado promedio.

Utilizaremos de nuevo como medida el promedio del **F1-Score** en los *folds*. Si hay empate en dicha media, se elegirá el modelo con menor desviación típica de la métrica.

5.4.2. Resultados

Para permitir la reproducibilidad de los experimentos, se utilizó 100 como semilla de generación de números aleatorios.

5.4.2.1 RNA

Para el entrenamiento de las RNA, se han utilizado los siguientes parámetros en común:

- Ratio de aprendizaje: 0,01
- Ratio de patrones para el conjunto de validación: 0,2.
- Máximo número de ciclos (*epochs*) de entrenamiento: 1500.
- Máximo número de ciclos (*epochs*) de entrenamiento sin mejorar el error de validación: 5.
- Algoritmo de optimización: ADAM.
- Función de *loss*: *Cross Entropy*.

El hiperparámetro que hemos variado ha sido, de nuevo, la arquitectura de neuronas a utilizar, obteniendo 8 configuraciones diferentes.

Se muestran los resultados de la experimentación en la Tabla 34.

5.4.2.2 SVM

Para las máquinas de soporte vectorial hemos utilizado 8 configuraciones distintas de los hiperparámetros de *kernel*, grado del *kernel* (sólo se utiliza en *kernel* polinomial), *gamma* y *C*.

Se muestran los resultados de la experimentación en la Tabla 35.

Tabla 27: Resultados RNA

Arquitectura	F1-Score	Precisión
[16]	$0,95148 \pm 0,00551$	$0,96105 \pm 0,00471$
[32]	$0,98759 \pm 0,00345$	$0,9897 \pm 0,00221$
[64]	$0,99345 \pm 0,00309$	$0,99428 \pm 0,00162$
[128]	$0,99293 \pm 0,00258$	$0,99424 \pm 0,00123$
[256]	$0,99269 \pm 0,00345$	$0,9936 \pm 0,00299$
[512]	$0,98348 \pm 0,0061$	$0,98603 \pm 0,00423$
[64, 64]	$0,98322 \pm 0,00373$	$0,98554 \pm 0,00292$
[64, 128]	$0,9818 \pm 0,00226$	$0,98428 \pm 0,00227$

Tabla 28: Resultados SVM

(kernel, grado, gamma, C)	F1-Score	Precisión
(poly, 3, 1, 1)	$0,98957 \pm 0,00723$	$0,9911 \pm 0,00594$
(rbf, 3, 1, 1)	$0,08773 \pm 0,01527$	$0,09143 \pm 0,01179$
(sigmoid, 3, 1, 1)	$0,07182 \pm 0,00909$	$0,1393 \pm 0,01431$
(poly, 3, 10, 0,1)	$0,99152 \pm 0,00418$	$0,99191 \pm 0,00394$
(rbf, 3, 10, 0,1)	$0,00068 \pm 3,0e - 5$	$0,02965 \pm 0,00136$
(rbf, 3, 0,001, 100)	$0,99605 \pm 0,00408$	$0,99612 \pm 0,00324$
(rbf, 3, 0,01, 100)	$0,9947 \pm 0,00389$	$0,99459 \pm 0,00313$
(poly, 3, 100, 0,001)	$0,99142 \pm 0,00449$	$0,99237 \pm 0,00367$

5.4.2.3 Árboles de decisión

Para los árboles de decisión hemos utilizado 6 configuraciones distintas del hiperparámetro de profundidad máxima.

Se muestran los resultados de la experimentación en la Tabla 36.

Tabla 29: Resultados Árbol de decisión

Altura máxima	F1-Score	Precisión
32	$0,93688 \pm 0,0118$	$0,94355 \pm 0,00995$
64	$0,92919 \pm 0,01756$	$0,93871 \pm 0,01425$
128	$0,92578 \pm 0,02024$	$0,93693 \pm 0,01502$
256	$0,93336 \pm 0,01516$	$0,94104 \pm 0,01578$
512	$0,93528 \pm 0,01411$	$0,9438 \pm 0,01019$
1024	$0,93482 \pm 0,01642$	$0,94221 \pm 0,01563$

5.4.2.4 kNN

Para el modelo kNN hemos utilizado 6 configuraciones distintas del hiperparámetro de k (número de vecinos más cercanos).

Se muestran los resultados de la experimentación en la tabla 37.

Tabla 30: Resultados kNN

K	F1-Score	Precisión
2	$0,98126 \pm 0,00699$	$0,98422 \pm 0,00492$
3	$0,98306 \pm 0,00593$	$0,98473 \pm 0,00477$
7	$0,97125 \pm 0,00862$	$0,9767 \pm 0,00708$
15	$0,95195 \pm 0,01088$	$0,96343 \pm 0,00783$
31	$0,93762 \pm 0,01577$	$0,95012 \pm 0,01025$
63	$0,88327 \pm 0,01502$	$0,91107 \pm 0,00954$

5.4.3. Discusión

Como se puede ver en los resultados, el funcionamiento de nuestro sistema resolviendo el problema completo, es decir, clasificando todas las notas del piano, es sorprendente. Con el mejor modelo (de nuevo un SVM), obtuvimos una precisión de $0,99612 \pm 0,00324$ y un F1-Score de $0,99605 \pm 0,00408$, haciendo uso de un *kernel* de base radial, un valor de *gamma* 0,001 y un valor de C 100.

De nuevo destacar que, a pesar de obtener RNAs con valores de F1-Score muy altos (>99 %), el tiempo invertido en el entrenamiento las hace modelos menos interesantes, sobre todo comparados con los modelos basados en SVM o kNN.

Con respecto a las características, creemos que tanto la **frecuencia máxima absoluta** y la **intensidad máxima absoluta en frecuencia**, son importantes a la hora de clasificar correctamente las notas. Sin embargo, ahora que tenemos el problema completo resuelto, consideramos que es el momento de tratar de minimizar el número de características necesarias, perdiendo la menor precisión en la clasificación posible. Este aspecto será en el que nos centremos en la siguiente aproximación.

Se muestra en la Tabla 38 la matriz de confusión del mejor modelo obtenido. En ella, podemos observar como se confunde mayoritariamente en notas que se encuentran a distancias cercanas como son $C7$ y $C\#7$ o $A1$ y $A\#1$.

		Predicc.																																				
		C1	C2	C3	C4	C5	C6	C7	C8	A1	A2	...	B4	B5	B6	B7	D1	...	E1	E2	E3	...	E6	E7	F1	F2	F3	...	F6	F7	G1	G2	G3	G4	G5	G6	G7	
Real	C1	7	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	
	C2	0	7	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	
	C3	0	0	11	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	0
	C4	0	0	0	15	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	0
	C5	0	0	0	0	32	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	0
	...																																					
	B5	0	0	0	0	0	0	0	0	0	0		0	14	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	0
	B6	0	0	0	0	0	0	0	0	1	0		0	0	18	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	0
	B7	0	0	0	0	0	0	0	0	0	0		0	0	0	14	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	0	0	0
	...																																					
	E7	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	17	0	0	0		0	0	0	0	0	0	0	0	0	0
	F1	0	0	0	0	0	0	0	0	0	2		0	0	0	0	0		0	0	0		0	0	4	0	0		0	0	0	0	0	0	0	0	0	0
	F2	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	12	0		0	0	0	0	0	0	0	0	0	0
	...																																					
	F7	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	15	0	0	0	0	0	0	0	0
	G1	0	0	0	0	0	0	0	0	0	3		0	0	0	0	0		0	1	0		0	0	0	0	0		0	0	5	0	0	0	0	0	0	0
	G2	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	12	0	0	0	0	0	0	0
	G3	0	0	0	0	0	0	0	0	0	2		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	5	0	0	0	0	0	
	G4	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	11	0	0	0	0	
	G5	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	10	0	0	0	
	G6	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	7	0	0	
	G7	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0		0	0	0		0	0	0	0	0		0	0	0	0	0	0	0	17		

Tabla 31: Matriz de confusión mejor modelo

5.5. Quinta aproximación

5.5.1. Descripción

Las notas que vamos a clasificar constituyen el total de notas del piano, por lo que en esta aproximación será donde veamos cómo de bien se comporta nuestro sistema ante el problema completo. En concreto, las nuevas notas que añadimos son los sostenidos de cada escala. Estos presentan un especial problema, ya que solo están a distancia de un semitono con respecto a la nota original, resultando en frecuencias muy cercanas.

Se muestran a continuación los parámetros de normalización (volveremos a utilizar media cero) para cada característica en las Tablas 32, 33 25 y 26.

Tabla 32: Parámetros de normalización (I)

Característica	Media	Desviación Típica
E	0,005290622	0,009127998
zero-crossing	3317,7852	4477,6226
abs-max	1445,9364	1557,9128
abs-max-freq	980,58826	1027,9849
m ₁	2,5213237	4,892542
m ₂	19,776129	34,19082
m ₃	18,500994	33,448643
m ₄	20,293629	28,46877
m ₅	15,832674	24,200994
m ₆	13,741416	21,621166
m ₇	13,71829	20,745993
m ₈	10,299257	17,33558
m ₉	9,490465	18,469109
m ₁₀	9,750799	19,446434
m ₁₁	9,340946	13,882007
m ₁₂	7,7851214	11,177626
m ₁₃	6,734947	13,808262
m ₁₄	5,5433474	8,790224
m ₁₅	4,2768292	6,906526
m ₁₆	4,459063	7,8797054
m ₁₇	2,9236934	5,253287
m ₁₈	2,6162808	5,561383
m ₁₉	2,5326357	4,6802435
m ₂₀	1,656642	4,287465
m ₂₁	1,6121823	4,2043204
m ₂₂	1,1647563	3,044825
m ₂₃	0,87163603	2,4234502
m ₂₄	0,83163273	2,1765046
m ₂₅	0,61601394	1,4981358
m ₂₆	0,5027224	1,2157471
m ₂₇	0,44925115	1,2129601
m ₂₈	0,3179743	1,0582143
m ₂₉	0,30106485	1,2961926
m ₃₀	0,12668554	0,24906345

Tabla 33: Parámetros de normalización (II)

Característica	Media	Desviación Típica
std ₁	3,7071	8,894764
std ₂	41,93409	100,38277
std ₃	41,496273	100,46413
std ₄	50,62945	97,251366
std ₅	32,27192	66,25659
std ₆	31,772036	64,703476
std ₇	30,200518	56,291985
std ₈	24,33468	49,075897
std ₉	17,22069	40,07678
std ₁₀	21,47563	49,664173
std ₁₁	16,356256	32,295124
std ₁₂	13,809475	27,013056
std ₁₃	13,494098	35,255543
std ₁₄	9,511233	19,50926
std ₁₅	7,4176326	16,4802
std ₁₆	7,555132	18,873085
std ₁₇	5,6317873	11,938161
std ₁₈	3,8923404	10,900163
std ₁₉	4,617325	10,1336155
std ₂₀	2,5670214	8,334569
std ₂₁	2,7792637	7,7385535
std ₂₂	1,8842899	5,510914
std ₂₃	1,4960651	4,586712
std ₂₄	1,4450701	3,7847013
std ₂₅	0,90402246	2,5514781
std ₂₆	0,7006507	1,8386049
std ₂₇	0,6376248	1,6106461
std ₂₈	0,48451066	1,7358224
std ₂₉	0,38622695	1,3208534
std ₃₀	0,18503572	0,458966

Donde:

- E indica la **energía de la señal**.
- m_i indica la **media de la intensidad** en el intervalo i en frecuencia.
- std_i indica la **desviación típica de la intensidad** en el intervalo i en frecuencia.
- max_i indica el **máximo de la intensidad** en el intervalo i en frecuencia.
- $max-freq_i$ indica la **frecuencia donde se alcanza el máximo de intensidad** en el intervalo i en frecuencia.

Para estos experimentos se volvió a repetir 20 veces el entrenamiento de la RNA en cada *fold*, devolviendo el resultado promedio.

Utilizaremos de nuevo como medida el promedio del **F1-Score** en los *folds*. Si hay empate en dicha media, se elegirá el modelo con menor desviación típica de la métrica.

5.5.2. Resultados

Para permitir la reproducibilidad de los experimentos, se utilizó 100 como semilla de generación de números aleatorios.

5.5.2.1 RNA

Para el entrenamiento de las RNA, se han utilizado los siguientes parámetros en común:

- Ratio de aprendizaje: 0,01
- Ratio de patrones para el conjunto de validación: 0,2.
- Máximo número de ciclos (*epochs*) de entrenamiento: 1500.
- Máximo número de ciclos (*epochs*) de entrenamiento sin mejorar el error de validación: 5.
- Algoritmo de optimización: ADAM.
- Función de *loss*: *Cross Entropy*.

El hiperparámetro que hemos variado ha sido, de nuevo, la arquitectura de neuronas a utilizar, obteniendo 8 configuraciones diferentes.

Se muestran los resultados de la experimentación en la Tabla 34.

5.5.2.2 SVM

Para las máquinas de soporte vectorial hemos utilizado 8 configuraciones distintas de los hiperparámetros de *kernel*, grado del *kernel* (sólo se utiliza en *kernel* polinomial), *gamma* y *C*.

Se muestran los resultados de la experimentación en la Tabla 35.

Tabla 34: Resultados RNA

Arquitectura	F1-Score	Precisión
[16]	$0,91452 \pm 0,00544$	$0,92437 \pm 0,00475$
[32]	$0,97012 \pm 0,00554$	$0,97169 \pm 0,00485$
[64]	$0,98034 \pm 0,00697$	$0,98149 \pm 0,00567$
[128]	$0,98007 \pm 0,00613$	$0,98054 \pm 0,00449$
[256]	$0,9757 \pm 0,0058$	$0,97508 \pm 0,00582$
[512]	$0,94062 \pm 0,00657$	$0,94438 \pm 0,00534$
[64, 64]	$0,95589 \pm 0,00402$	$0,95973 \pm 0,00353$
[64, 128]	$0,95232 \pm 0,00708$	$0,95488 \pm 0,00592$

Tabla 35: Resultados SVM

(kernel, grado, gamma, C)	F1-Score	Precisión
(poly, 3, 1, 1)	$0,98565 \pm 0,00523$	$0,9872 \pm 0,00429$
(rbf, 3, 1, 1)	$0,13958 \pm 0,01127$	$0,12843 \pm 0,0095$
(sigmoid, 3, 1, 1)	$0,0372 \pm 0,00548$	$0,10149 \pm 0,00667$
(poly, 3, 10, 0,1)	$0,98545 \pm 0,00508$	$0,98636 \pm 0,00365$
(rbf, 3, 10, 0,1)	$0,00068 \pm 3,0e - 5$	$0,02965 \pm 0,00136$
(rbf, 3, 0,001, 100)	$0,99186 \pm 0,00543$	$0,99156 \pm 0,00571$
(rbf, 3, 0,01, 100)	$0,99375 \pm 0,00263$	$0,99315 \pm 0,00212$
(poly, 3, 100, 0,001)	$0,98557 \pm 0,00386$	$0,98683 \pm 0,00308$

5.5.2.3 Árboles de decisión

Para los árboles de decisión hemos utilizado 6 configuraciones distintas del hiperparámetro de profundidad máxima.

Se muestran los resultados de la experimentación en la Tabla 36.

Tabla 36: Resultados Árbol de decisión

Altura máxima	F1-Score	Precisión
32	$0,93524 \pm 0,01075$	$0,9389 \pm 0,00772$
64	$0,92723 \pm 0,01297$	$0,93348 \pm 0,01031$
128	$0,93011 \pm 0,01126$	$0,93468 \pm 0,01126$
256	$0,93144 \pm 0,01067$	$0,93798 \pm 0,00985$
512	$0,92927 \pm 0,00971$	$0,93616 \pm 0,00711$
1024	$0,92633 \pm 0,01424$	$0,93278 \pm 0,01285$

5.5.2.4 kNN

Para el modelo kNN hemos utilizado 6 configuraciones distintas del hiperparámetro de k (número de vecinos más cercanos).

Se muestran los resultados de la experimentación en la tabla 37.

Tabla 37: Resultados kNN

K	F1-Score	Precisión
2	$0,9699 \pm 0,00444$	$0,9699 \pm 0,00401$
3	$0,9739 \pm 0,0055$	$0,97356 \pm 0,00475$
7	$0,96825 \pm 0,00482$	$0,96936 \pm 0,00492$
15	$0,95356 \pm 0,01199$	$0,95761 \pm 0,00756$
31	$0,92823 \pm 0,01575$	$0,93464 \pm 0,01214$
63	$0,88728 \pm 0,01083$	$0,90243 \pm 0,00881$

5.5.3. Discusión

Como se puede ver en los resultados, el funcionamiento de nuestro sistema resolviendo el problema completo, es decir, clasificando todas las notas del piano, es sorprendente. Con el mejor modelo (de nuevo un SVM), obtuvimos una precisión de $0,99612 \pm 0,00324$ y un F1-Score de $0,99605 \pm 0,00408$, haciendo uso de un *kernel* de base radial, un valor de *gamma* 0,001 y un valor de C 100.

De nuevo destacar que, a pesar de obtener RNAs con valores de F1-Score muy altos ($>99\%$), el tiempo invertido en el entrenamiento las hace modelos menos interesantes, sobre todo comparados con los modelos basados en SVM o kNN.

Con respecto a las características, creemos que tanto la **frecuencia máxima absoluta** y la **intensidad máxima absoluta en frecuencia**, son importantes a la hora de clasificar correctamente las notas. Sin embargo, ahora que tenemos el problema completo resuelto, consideramos que es el momento de tratar de minimizar el número de características necesarias, perdiendo la menor precisión en la clasificación posible. Este aspecto será en el que nos centremos en la siguiente aproximación.

Se muestra en la Tabla 38 la matriz de confusión del mejor modelo obtenido. En ella, podemos observar como se confunde mayoritariamente en notas que se encuentran a distancias cercanas como son $C7$ y $C\#7$ o $A1$ y $A\#1$.

		Predict.																																			
		C1	C2	C3	C4	C5	C6	C7	C8	A1	A2	...	B4	B5	B6	B7	D1	...	E1	E2	E3	...	E6	E7	F1	F2	F3	...	F6	F7	G1	G2	G3	G4	G5	G6	G7
Real	C1	7	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C2	0	7	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C3	0	0	11	0	0	0	0	0	0	0	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C4	0	0	0	15	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	C5	0	0	0	0	32	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	...																																				
	B5	0	0	0	0	0	0	0	0	0	0		0	14	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	B6	0	0	0	0	0	0	0	1	0	0	...	0	0	18	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	B7	0	0	0	0	0	0	0	0	0	0		0	0	0	14	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	0
	...																																				
	E7	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	17	0	0	0	...	0	0	0	0	0	0	0	0	0
	F1	0	0	0	0	0	0	0	0	0	2	...	0	0	0	0	0	...	0	0	0	...	0	0	4	0	0	...	0	0	0	0	0	0	0	0	0
	F2	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	12	0	...	0	0	0	0	0	0	0	0	0
	...																																				
	F7	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	15	0	0	0	0	0	0	0
	G1	0	0	0	0	0	0	0	0	0	3	...	0	0	0	0	0	...	0	1	0	...	0	0	0	0	0	...	0	0	5	0	0	0	0	0	0
	G2	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	12	0	0	0	0	0
	G3	0	0	0	0	0	0	0	0	0	2	...	0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	5	0	0	0	0
	G4	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	11	0	0	0
	G5	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	10	0	0
	G6	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	7	0
	G7	0	0	0	0	0	0	0	0	0	0		0	0	0	0	0	...	0	0	0	...	0	0	0	0	0	...	0	0	0	0	0	0	0	0	17

Tabla 38: Matriz de confusión mejor modelo

6. Conclusiones

7. Trabajo futuro

8. Bibliografía

Referencias

- Baevski, A., Hsu, W.-N., Conneau, A., & Auli, M. (2021). Unsupervised speech recognition. *Advances in Neural Information Processing Systems*, 34.
- Benetos, E., Dixon, S., Duan, Z., & Ewert, S. (2018). Automatic music transcription: An overview. *IEEE Signal Processing Magazine*, 36(1), 20-30.
- Chang, S., Lee, J., Choe, S. K., & Lee, K. (2017). Audio cover song identification using convolutional neural network. *arXiv preprint arXiv:1712.00166*.
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3), 273-297.
- Foo, S. W., & Wong, P. L. (1999). Recognition of piano notes. *IEEE International Conference on Information, Communications and Signal Processing (1999: Singapore)*.
- Guo, G., Wang, H., Bell, D., Bi, Y., & Greer, K. (2003). KNN model-based approach in classification. *OTM Confederated International Conferences. On the Move to Meaningful Internet Systems*, 986-996.
- Klapuri, A. (2004). *Signal processing methods for the automatic transcription of music*. Tampere University of Technology Finland.
- Krogh, A. (2008). What are artificial neural networks? *Nature biotechnology*, 26(2), 195-197.
- Marolt, M., Kavcic, A., & Privosnik, M. (2002). Neural networks for note onset detection in piano music. *Proceedings of the 2002 International Computer Music Conference*.

- Myles, A. J., Feudale, R. N., Liu, Y., Woody, N. A., & Brown, S. D. (2004). An introduction to decision tree modeling. *Journal of Chemometrics: A Journal of the Chemometrics Society*, 18(6), 275-285.
- Osmalsky, J., Embrechts, J.-J., Van Droogenbroeck, M., & Pierard, S. (2012). Neural networks for musical chords recognition. *Journées d'informatique musicale*, 39-46.
- Solanki, A., & Pandey, S. (2019). Music instrument recognition using deep convolutional neural networks. *International Journal of Information Technology*, 1-10.